

Fine-tune mô hình ngôn ngữ GPT-2 tiếng Việt cho suy luận toán học

1st Lê Quang Khải
Computer Science, FIT-UET
23021593@vnu.edu.vn

2nd Trần Tuấn Huy
Computer Science, FIT-UET
23021581@vnu.edu.vn

Tóm tắt nội dung—Bài báo này khảo sát một chuỗi thực nghiệm fine-tuning trên backbone NlpHUST/gpt2-vietnamese nhằm giải toán lời văn tiếng Việt trong thiết lập tính điểm dựa trên đáp án số cuối cùng. Trên phương diện kỹ thuật, công trình so sánh nhiều họ phương pháp: full-solution supervised fine-tuning, compact-reasoning targets, answer-only LoRA, reward-tuning nhẹ, source-aware checkpoint selection và hybrid retrieval theo type/source. Trên phương diện khoa học, công trình kiểm tra liệu cải thiện điểm số có phản ánh reasoning robust hay chỉ phản ánh metric alignment, memorization ở mức source và rationalization hậu nghiệm. Kết quả cho thấy point gain lớn nhất xuất hiện khi tối ưu trực tiếp tín hiệu đáp án và khi bổ sung retrieval chọn lọc; trong khi đó, các chỉ dấu robust reasoning giảm mạnh ở source-unseen, ở các biến thể perturbation như FOBAR/SV, và khi retrieval bị ép áp dụng lên các kiểu dữ liệu mismatch. Báo cáo đề xuất một protocol đánh giá thận trọng hơn cho small language models: tách riêng final-answer accuracy, source-overlap advantage, retrieval dependence, answer-signal dilution và reasoning faithfulness.

Index Terms—reasoning toán học, GPT-2 tiếng Việt, LoRA, retrieval, source overlap, faithfulness, small language models

I. GIỚI THIỆU

Backbone của toàn bộ chuỗi thí nghiệm là NlpHUST/gpt2-vietnamese, một mô hình causal language modeling kiểu GPT-2, với 12 layer và hidden size 768, được pretrain trên Vietnamese Oscar bằng mục tiêu CLM; model card công bố mô hình đạt khoảng 13.4 perplexity trên một validation set từ Oscar. Điều này đặt hệ thống vào đúng vùng quan tâm của bài toán nghiên cứu: một small language model theo nghĩa kiến trúc và năng lực, thay vì một reasoning model cỡ lớn có compute test-time dồi dào.

Vấn đề cốt lõi của toán lời văn không chỉ là sinh ra một câu trả lời “giống lời giải”, mà là thực hiện đồng thời nhiều phép biến đổi: hiểu ngôn ngữ tự nhiên, trích xuất đại lượng, xác định quan hệ, chọn phép toán, tính toán trung gian và cuối cùng định dạng đáp án sao cho parser của hệ thống chấm điểm có thể đọc đúng. Trong một thiết lập như vậy, có ít nhất hai con đường khác nhau để điểm số tăng: hoặc mô hình thực sự học được một phần reasoning có khả năng chuyển giao, hoặc mô hình học shortcut thuận lợi cho metric, chẳng hạn định dạng đáp án, mapping ở mức template/source, hoặc sinh rationale hậu nghiệm sau khi “đã biết” đáp án. Literature về faithfulness của chain-of-thought nhiều lần nhấn mạnh rằng reasoning chain sinh ra bằng ngôn ngữ tự nhiên không đương nhiên phản ánh cơ chế thật sự sinh đáp án.

Trong bối cảnh đó, báo cáo này không đặt mục tiêu chứng minh GPT-2 “biết suy luận toán” theo nghĩa mạnh, mà đặt mục tiêu hẹp hơn nhưng nghiêm ngặt hơn: xác định loại năng lực nào đã thực sự được học, năng lực nào chỉ là source-local memory, và phần nào của pipeline chịu trách nhiệm cho mức tăng score quan sát được. Đây là cách đặt vấn đề phù hợp với các benchmark như LILA, vốn nhấn mạnh rằng đánh giá mathematical reasoning đáng tin cậy phải xem xét cả robustness, out-of-distribution behavior và language perturbation, không chỉ in-domain accuracy.

A. Định nghĩa bài toán và ràng buộc

Bài toán của dự án là sinh đầu ra model_output cho mỗi câu hỏi toán tiếng Việt, trong đó mục tiêu thực tế của hệ thống chấm là trích đúng đáp án số cuối cùng. Về phía backbone, toàn bộ thực nghiệm khóa vào NlpHUST/gpt2-vietnamese; đây là causal LM phù hợp cho các thiết kế SFT/LoRA dạng autoregressive.

Một cách viết gọn cho metric lỗi là:

$$\text{relerr}(\hat{y}, y) = \frac{|\hat{y} - y|}{\max(1, |y|)}. \quad (1)$$

Trong analytics của dự án, output được bucket hóa thành bốn mức Exact (10), Near (5), Partial (1) và Fail (0), như thể hiện trực tiếp trong Figure 3 và trong các bảng báo cáo điểm. Các ngưỡng bucket cụ thể cần được giữ nguyên văn từ task specification/notebook gốc khi chốt PDF camera-ready; trong phiên truy xuất này, phần rubric chi tiết không hiện diện như một artifact độc lập nên được giữ ở mức mô tả công thức và bucket.

B. Công trình liên quan

Nhánh công trình gần nhất về post-training cho toán học là solution-supervised fine-tuning và các biến thể instruction tuning trên corpus toán có rationale. MAMmoTH cho thấy dữ liệu instruction toán đa dạng và hybrid CoT/PoT có thể nâng mạnh chất lượng giải toán, nhấn mạnh vai trò của data diversity và rationale design trong mathematical reasoning. Một hướng quan trọng khác là relational abstraction, trong đó Nam và cộng sự chỉ ra rằng rationale ngôn ngữ tự nhiên thông thường chưa chắc là hình thức biểu diễn reasoning tốt nhất; những chuỗi biểu diễn quan hệ trừu tượng hơn có thể hỗ trợ tốt hơn cho generalization.

Bảng 1

RÀNG BƯỚC CHÍNH CỦA BÀI TOÁN VÀ HỆ QUẢ PHƯƠNG PHÁP. RÀNG BƯỚC KỸ THUẬT ƯU TIÊN PEFT, TARGET NGẮN, DECODE ỔN ĐỊNH; METRIC DỰA TRÊN ĐÁP ÁN SỐ CÓ THỂ THUỞNG CHO ANSWER EXTRACTION MẠNH HƠN REASONING TEXT THUẦN TÚY.

Thành phần	Đặc tả dùng trong báo cáo	Hệ quả phương pháp
Backbone	NlpHUST/gpt2-vietnamese, causal LM, 12 layer, hidden 768	Phù hợp với LoRA/PEFT; năng lực suy luận nội tại bị giới hạn bởi quy mô mô hình
Dữ liệu	Tập train/valid/test của bài toán; analytics hiện có cho valid gồm 1000 mẫu	Cần kiểm toán overlap ở level source, không chỉ query
Môi trường	Notebook Kaggle offline; runtime Kaggle end-to-end chưa điều ở bản này	Ưu tiên target ngắn, decode ổn định, train gọn
Inference	Không cập nhật trọng số tại test	Không được dựa vào online learning
Output	model_output phải cho phép parse số cuối cùng; có hoặc không có rationale đều phải ưu tiên extractability	Các chiến lược answer-only có thể thắng full-solution
Metric	Relative error + bucket Exact/Near/Partial/Fail	Final-answer alignment có thể quan trọng hơn “lời giải đẹp”

Ở lớp hạ tầng fine-tuning, LoRA được Hu và cộng sự đề xuất như một cơ chế low-rank adaptation giúp giảm rất mạnh số tham số phải học trong khi giữ cố định trọng số gốc; tài liệu PEFT của Hugging Face mô tả đúng trực giác này: thay vì cập nhật trực tiếp toàn bộ ma trận trọng số, ta học hai ma trận cập nhật hạng thấp rồi cộng vào trọng số gốc, đồng thời có thể merge adapter để tránh thêm độ trễ suy luận. Đây là lý do LoRA đặc biệt phù hợp với một mô hình GPT-2 nhỏ trong môi trường Kaggle bị ràng buộc về thời gian và bộ nhớ.

Với teacher-generated supervision hay compact rationale do teacher tạo ra, logic của dự án nằm gần với knowledge distillation: student nhỏ học cách bắt chước một target “giàu thông tin” nhưng rẻ hơn ở inference. Hinton, Vinyals và Dean đặt nền tảng cho hướng này bằng luận điểm rằng mô hình nhỏ có thể nén lại tri thức của mô hình hoặc ensemble lớn hơn dưới một dạng supervision hữu ích hơn so với hard labels đơn thuần.

Cuối cùng, nếu pipeline bổ sung explicit memory theo source/group thì về mặt khái niệm, nó gần với họ retrieval-augmented generation: tách kiến thức/đáp án có thể truy hồi khỏi phần parametric memory của LM. Tuy nhiên, khác với RAG chuẩn trên kho tri thức lớn, retrieval của dự án là retrieval có kiểm soát theo source group và problem type, gần hơn với một “non-parametric answer memory” cục bộ chứ không phải một retriever sinh ngữ đầy đủ. Về đánh giá, các nghiên cứu như LILA và Faithful CoT nhắc rằng final-answer accuracy cần được tách khỏi faithfulness của reasoning và khỏi robustness dưới shift/perturbation. Đây chính là khung lý thuyết mà báo cáo này sử dụng để đọc lại kết quả thực nghiệm.


II. PHÂN TÍCH DỮ LIỆU

A. Kiểm tra Leakage

Toàn bộ analytics của dự án cho thấy tập train gồm 95,400 mẫu và valid gồm 1,000 mẫu, trải trên tám problem type. Nếu nhìn theo họ kiểu bài, nhóm Rephrased + AnsAug chiếm khoảng 71.5% train và 69.5% valid, trong khi nhóm FOBAR + SV chỉ chiếm khoảng 28.5% train và 30.5% valid. Điều này quan trọng vì các type dễ hơn, có nhiều biến thể gần source hơn, đồng thời là nơi retrieval mang lại lợi ích lớn nhất về sau. Từ bảng phân bố, ta cũng thấy dữ liệu có 33,746 unique source groups, tương đương trung bình khoảng 2.83

train variants mỗi source group; riêng MATH_AnsAug đạt gần 3.88 variants/source, cao nhất toàn bộ bảng, gợi ý nguy cơ source-memory lớn hơn ở chính type này.

Hình quan trọng nhất để hiểu split design là Figure 1. Phần bên trái mô tả source-overlap query-disjoint: query cụ thể được giữ tách biệt, nhưng các held-out query vẫn đến từ các source groups từng có trong train. Phần bên phải mô tả source-disjoint validation: toàn bộ original-problem groups bị loại khỏi train. Figure 1 còn ghi rõ trong split overlap có 10,784 shared source groups dù exact query overlap vẫn bằng 0. Điều đó có nghĩa là “query-disjoint” không thể tự động được đọc thành “generalization sang bài toán mới”. Figure 2 biến trực



Hình 1. Source/query overlap structure. Source-overlap query-disjoint vẫn giữ lại nhiều biến thể từ cùng bài gốc, trong khi source-disjoint loại cả source group khỏi train.


giác đó thành số. Exact query overlap bằng 0% cho cả tám type, nhưng source-group overlap rất cao: GSM_Rephrased và GSM_SV đạt 100%, GSM_AnsAug 98.1%, GSM_FOBAR 98.4%, MATH_AnsAug vẫn còn 89.6%, còn các type MATH khác nằm khoảng 94.0%–95.6%. Đồng thời, max same-source

Bảng II

PHÂN BỐ PROBLEM TYPES VÀ SOURCE GROUPS. BẢNG TÁCH RIÊNG SỐ LƯỢNG MẪU THỎ VÀ SỐ SOURCE GROUPS, CHO THẤY DỮ LIỆU CÓ NHIỀU BIẾN THỂ AUGMENTATION PHÁT SINH TỪ CÙNG MỘT BÀI GỐC; ĐIỀU NÀY LÀ NỀN TẢNG CHO TOÀN BỘ PHÂN TÍCH LEAKAGE THEO SOURCE.

Type	#Train	#Valid	#Unique source groups	Avg query length	Avg answer length	Notes
GSM_Rephrased	20028	197	6454	49.68	90.06	paraphrased GSM-style
GSM_AnsAug	18745	209	6453	53.19	89.34	answer-augmented variant
GSM_FOBAR	10023	122	4438	79.22	151.21	FOBAR perturbation from GSM sources
GSM_SV	9869	97	4792	66.64	193.52	symbol/variable GSM-style variant
MATH_Rephrased	12477	116	4040	27.24	89.81	paraphrased MATH-style
MATH_AnsAug	16999	173	4377	27.62	84.79	answer-augmented MATH variant
MATH_FOBAR	3668	45	1696	65.02	225.93	FOBAR perturbation from MATH sources
MATH_SV	3591	41	1496	53.03	187.22	symbol/variable MATH-style variant

query similarity dao động từ 66.7% đến 88.7%. Đây là bằng chứng trực tiếp cho thấy nếu chỉ dùng query-disjoint validation, mô hình vẫn có thể dựa rất mạnh vào source-level regularities. Chính vì vậy, mọi claim về reasoning nếu chỉ dựa trên overlap-valid đều phải được hạ giọng.



Hình 2. Phân tích overlap giữa train và validation set. Exact query overlap bằng 0 không đồng nghĩa với dữ liệu sạch leakage; source-group overlap vẫn cực cao, cho phép source-memory và pattern matching hoạt động mạnh.

Một insight quan trọng khác từ Table 2 là độ dài lời giải trung bình tăng rất mạnh ở các type khó hơn. MATH_FOBAR có Avg answer length 225.93, GSM_SV 193.52, MATH_SV 187.22, trong khi các type Rephrased và AnsAug thường quanh 84–90 token. Điều này báo trước một hiện tượng quan trọng ở phần sau: full-solution SFT trên dữ liệu khó hơn sẽ phải tối ưu một target dài và không đồng đều, khiến tín hiệu cập nhật trực tiếp cho “đáp án cuối” bị loãng hơn.

B. Giao thức đánh giá

Vì metric chính của bài toán xoay quanh đáp án số cuối cùng, giao thức đánh giá của báo cáo cần tách rõ giữa độ đúng của final answer và chất lượng reasoning. Nếu không tách hai lớp này, một answer-only model rất mạnh sẽ dễ bị hiểu nhầm là “reasoning model”, trong khi thực tế nó chỉ rất giỏi tối ưu đúng chỗ mà metric thưởng.

Figure 3 là minh họa định lượng tốt nhất cho cách giao thức này phân biệt accuracy và robustness. Ở panel trái, các type GSM_Rephrased, MATH_Rephrased và MATH_AnsAug có phần lớn khối lượng nằm ở bucket Exact (10), trong khi

Bảng III

QUY TRÌNH ĐÁNH GIÁ ĐỘ CHÍNH XÁC CỦA CÂU TRẢ LỜI CUỐI CÙNG VÀ TÍNH VỮNG CHẮC CỦA LẬP LUẬN. BẢNG BỔ SUNG CÁC DIAGNOSTICS CẦN THIẾT ĐỂ KHÔNG ĐỒNG NHẤT FINAL-ANSWER ACCURACY VỚI ROBUST REASONING. Ý TƯỞNG VỀ ROBUSTNESS VÀ FAITHFULNESS ĐƯỢC THỨC ĐÁY BỞI LILA VÀ FAITHFUL COT.


Metric	Định nghĩa	Ý nghĩa
Official-valid score	Điểm trung bình theo rubric Exact/Near/Partial/Fail trên valid	Metric chính của bài toán
Type-wise official-valid	Official-valid tách theo từng problem type	Xác định mô hình mạnh/yếu ở đâu
Extractability	Tỉ lệ output parse được đáp án số cuối	Đo mức ổn định định dạng
Overlap-valid score	Điểm trên split source-overlap query-disjoint	Đo năng lực trên biến thể cùng source
Source-disjoint score	Điểm trên split loại cả source group khỏi train	Chỉ số robustness quan trọng nhất
Fail rate by source-overlap class	Tỉ lệ score = 0 theo lớp seen/unseen/conflict/missing	Chẩn đoán phụ thuộc source-memory
Hybrid gain	Hybrid score trừ model-only score	Tách lợi ích retrieval khỏi generator
Retrieval usage	Tỉ lệ mẫu được retriever xử lý	Đo mức phụ thuộc explicit memory
Reasoning faithfulness rate	$\#(\text{correct answer} \ \& \ \text{valid reasoning})/\#(\text{correct answer})$	Chỉ số cốt lõi để loại rationalization
Robustness gap	$S_{\text{overlap}} - S_{\text{source-disjoint}}$	Đo mức lạc quan giả do overlap
Answer-signal dilution	$\rho_{\text{ans}} = k/l$	Đo phần loss gắn trực tiếp với đáp án cuối

các type GSM_FOBAR, GSM_SV, MATH_FOBAR, MATH_SV chuyển đáng kể sang Partial và đặc biệt là Fail. Panel phải thậm chí còn trực diện hơn: fail rate chỉ 9.8% cho “seen source same answer”, nhưng tăng lên 60.3% ở “seen source conflict”, 95.8% ở “seen source missing”, và 65.7% ở “source-unseen”. Nếu một mô hình thực sự học reasoning robust, ta kỳ vọng gradient của lỗi sẽ chủ yếu đến từ cấu trúc toán học của bài, chứ không phụ thuộc quyết định như vậy vào việc bài gốc đã từng xuất hiện trong train với cùng đáp án hay chưa.

III. PHƯƠNG PHÁP THỰC NGHIỆM

A. Backbone, objective và giả thuyết tín hiệu học

Mọi cấu hình trong project đều dựa trên một causal LM kiểu GPT-2. Theo model card, NlpHUST/gpt2-vietnamese là



Hình 3. Phân phối lỗi theo loại problem và các lớp source-overlap. Phần trái cho thấy độ khó chênh lệch rất mạnh giữa Rephrased/AnsAug và FOBAR/SV; phần phải cho thấy source-overlap là biến giải thích mạnh của failure.

mô hình GPT-2 đã được pretrain trên tiếng Việt bằng causal language modeling objective. Ở mức tối giản, bài toán fine-tuning dùng objective:

$$\mathcal{L}_{\text{SFT}} = \frac{1}{T} \sum_{t=1}^T \log p_{\theta}(y_t | x, y_{<t}). \quad (2)$$

Vì loss trung bình trên toàn bộ target tokens, một nhận xét lý thuyết đơn giản nhưng rất quan trọng là: nếu chỉ có (k) token cuối thực sự liên quan trực tiếp tới metric chấm, còn toàn bộ target dài (T) token, thì phần tín hiệu “gắn trực tiếp” với đáp án xấp xỉ:

$$\rho_{\text{ans}} = \frac{k}{T}. \quad (3)$$

Đây là Answer-Signal Dilution. Nếu lấy $(k \approx 5)$ token cho cụm neo đáp án cộng chuỗi số cuối, thì ở phiên bản compact equation với avg output length 83.6, $(\rho_{\text{ans}} \approx 5/83.6 \approx 6.0\%)$; ở phiên bản curriculum gồm answer-only warmup $\rightarrow$ compact-equation $\rightarrow$ mixed replay với 37.5, $(\rho_{\text{ans}} \approx 13.3\%)$. Với answer-only target dài cỡ 5–10 token, (ρ_{ans}) có thể tăng lên 50–100%. Điều này dự đoán chính xác xu hướng thực nghiệm: rút ngắn target có thể tăng điểm official-valid khá mạnh mà chưa chắc đã tăng source-disjoint reasoning.

B. LoRA, PEFT và giải mã

LoRA thay thế việc fine-tune toàn bộ trọng số bằng một cập nhật hạng thấp:

$$W' = W + \Delta W, \quad \Delta W = BA \quad (4)$$

trong đó $(A \in \mathbb{R}^{r \times d_{\text{in}}})$, $(B \in \mathbb{R}^{d_{\text{out}} \times r})$, và số tham số trainable cho một lớp tuyến tính xấp xỉ là:

$$N_{\text{LoRA}} = r(d_{\text{in}} + d_{\text{out}}). \quad (5)$$

Tài liệu PEFT của Hugging Face nêu rõ LoRA giữ nguyên trọng số gốc, học hai ma trận cập nhật nhỏ hơn, giảm lớn trainable parameters, và có thể merge sau huấn luyện để không thêm latency; paper gốc của Hu và cộng sự cũng báo cáo LoRA cạnh tranh tốt với full fine-tuning trên nhiều họ mô hình, bao gồm GPT-2.

Với GPT-2 nhỏ 12 layer, hidden size 768, nếu áp dụng LoRA theo kiểu attention-only lên c_{attn} và c_{proj} , số tham số trainable có thể ước lượng:

$$N_{\text{LoRA}} \approx 12 \left[(768 + 2304)r + (768 + 768)r \right] 55,296, r. \quad (6)$$

Khi đó, $r = 16$ cho khoảng 0.885M tham số trainable, còn $r = 32$ cho khoảng 1.769M. Nếu thêm cả c_{fc} , tổng tăng lên:

$$N'_{\text{LoRA}} \approx 101,376, r, \quad (7)$$

tức 3.244M tham số ở $r = 32$. Kết quả thực nghiệm của dự án khá khớp với trực giác low-rank capacity: ở pha answer-only sớm, $r = 16$ và $r = 32$ gần như ngang nhau, chỉ 1.789 so với 1.810. Điều này cho thấy ở giai đoạn này, rank chưa phải bottleneck chính; lựa chọn target, checkpoint và split validation quan trọng hơn bản thân việc tăng adapter capacity.

Về decoding, các notebook dùng chủ yếu beam2 hoặc beam4. Tài liệu Transformers của Hugging Face mô tả beam search là chiến lược duy trì nhiều chuỗi ứng viên đồng thời và phù hợp hơn cho các input-grounded tasks; đồng thời, paper của Kasai và cộng sự cảnh báo rằng beam search cần được báo cáo rõ cách dừng và cấu hình vì khác biệt nhỏ ở implementation có thể ảnh hưởng kết quả đáng kể. Việc dự án ghi rõ beam2 và beam4 là một thực hành tốt theo hướng này.

Bảng IV
SHORT-REASONING AND COMPACT-EQUATION VARIANTS

Ver	Target style	LoRA r	LR	Epochs	Max length
v2	full solution	SFT	5e-5	1	768
v3	answer-only reasoning $\rightarrow$ compact	SFT	5e-5	1	384
v4	KD compact reasoning + LoRA	16	5e-5	2	–
v5/v7	LoRA + GRPO-lite	16	–	staged	–
v9	compact-equation + source-disjoint selection	32	1e-3	8	256
v10	curriculum compact-equation	32	staged	2+4+2	256

Bảng V
ANSWER-ONLY AND RETRIEVAL-ENHANCED VARIANTS

Ver	Target style	LoRA r	LR	Epochs	Max length
v6	answer-only LoRA	16	5e-5	3	256
v8	answer-only + checkpoint selection	32	1e-3	8	256
v11	answer-only + overlap-valid	32	1e-3	8	256
v12	answer-only + broad source retrieval	32	1e-3	8	256
v13	type-gated retrieval + full retrain	32	1e-3	8	256
v14	retrieval gate sweep + full retrain	32	1e-3	8	256
v14-FS	extended retrieval for FOBAR/SV	32	1e-3	8	256

C. Thiết kế target

Nhóm phương pháp trong repo có thể được đọc lại theo bốn family target.

Family thứ nhất là **full-solution target**, tiêu biểu ở v2, trong đó toàn bộ lời giải tự nhiên được dùng làm target autoregressive. Ưu điểm là giữ lại rationale và đúng với trực giác “LM giải toán bằng lời”. Nhưng nhược điểm cũng rõ: target dài, tốn compute, dễ bị answer-signal dilution, và làm extractability kém khi parser cần một câu neo đáp án cuối thật ổn định.

Family thứ hai là **answer-only target**, đẩy gần như toàn bộ loss vào phần mô hình phải sinh được cụm đáp án cuối. Đây là family tạo bước nhảy lớn nhất về official-valid. Về mặt khoa học, nó không chứng minh reasoning; nhưng về mặt tối ưu task metric, nó cực kỳ hợp lý.

Family thứ ba là **compact-equation / compact reasoning target**, rút gọn lời giải thành các bước tính toán hoặc phương trình ngắn. Đây là lối thỏa hiệp giữa “có process signal” và “không làm target quá dài”.

Family thứ tư là **teacher/KD-derived compact supervision**, nơi một teacher giàu khả năng hơn cung cấp target ngắn gọn hơn, mạch lạc hơn, để student nhỏ học lại. Ở dự án này, nhánh v4 đại diện cho trực giác đó, nhưng số liệu định lượng hiện có vẫn chưa đầy đủ bằng các nhánh answer-only và hybrid retrieval.


D. Chọn checkpoint và pipeline retrieval

Một đóng góp phương pháp quan trọng của dự án không nằm ở backbone, mà ở checkpoint selection split. Điển hình như v8 vẫn chọn theo valid, v9–v10 chuyển qua source-disjoint, còn v11–v14 dùng source-overlap query-disjoint để phù hợp hơn với giả thiết hidden test có thể chứa biến thể cùng source. Về khoa học, thay đổi này rất quan trọng vì nó làm rõ “ta đang tối ưu cho cái gì”: robustness thực hay performance thực dụng trên test có source overlap.

Figure 5 cho thấy đường cong chọn checkpoint trên overlap-valid. v13 type-gated đạt đỉnh ở epoch 8, v14 gate sweep cũng chọn epoch 8, còn v14 FOBAR/SV đạt tốt nhất sớm hơn ở epoch 6 rồi giảm. Điều đó gợi ý rằng khi retrieval

được mở rộng sang các type khó hơn, hệ thống có xu hướng overfit sớm hơn vào quy luật không bền.

Về retrieval, dự án không dùng RAG đầy đủ kiểu dense retriever + generator, mà dùng một pipeline hẹp hơn: truy ra source group hoặc typed pool liên quan, kiểm tra confidence theo majority fraction, margin hoặc nearest-query Jaccard, rồi chỉ khi gate đạt chuẩn mới cho phép đáp án retrieved thay thế hoặc override đầu ra model. Tinh thần này vẫn gần với retrieval-augmented generation ở chỗ dùng explicit non-parametric memory để hỗ trợ phần parametric generator.




Hình 5. Kiến trúc retrieval-generation hybrid với cơ chế confidence gating. Hệ thống ưu tiên sử dụng đáp án được truy hồi khi độ tin cậy đủ cao, đồng thời kích hoạt GPT-2 LoRA để sinh đáp án trong các trường hợp truy hồi không đáng tin cậy.

Bảng gate chi tiết cho thấy v14 sweep chỉ bật retrieval cho GSM_Rephrased, GSM_AnsAug, MATH_AnsAug và MATH_Rephrased, với majority threshold cơ bản 0.34 và một số kiểu có thêm margin/Jaccard gate. v14 FOBAR/SV thì mở rộng sang FOBAR và SV bằng source_type_nearest_query với Jaccard rất cao (0.82–0.84), nhưng chính cấu hình này về sau cho kết quả tệ hơn trên một số type khó.

IV. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH LỖI

A. Kết quả thực nghiệm

Điểm đáng chú ý đầu tiên là baseline full-solution SFT khá yếu. V2 là minh họa tốt cho thất bại của trực giác “chỉ cần fine-tune lời giải là đủ”. Dù mô hình được phép sinh rationale dài, official-valid chỉ đạt 0.585, và khoảng 14.6% output còn không parse được đáp án cuối. Nếu nhìn dưới lăng kính metric, v2 học không hiệu quả vào nơi metric cần nó mạnh nhất. Kết quả v2 được minh họa trong Bảng 5.



Hình 4. Đường cong lựa chọn checkpoint dựa trên phân chia overlap-valid. Trong khi v13 và v14 sweep ổn định đến epoch 8, trong khi v14 FOBAR/SV đạt đỉnh sớm hơn tại epoch 6, gợi ý độ mong manh cao hơn của retrieval trên các type khó.

Bảng VI

FULL-SOLUTION SFT BASELINE. LONG TARGETS GIỮ ĐƯỢC REASONING TEXT NHƯNG PHÁ TÍNH ỔN ĐỊNH CỦA FINAL ANSWER TRONG RÀNG BUỘC RUNTIME VÀ PARSER.

Ver	Target	Max length	Decode	Valid score	Extractability	Runtime (h)
v2	full response	768	beam4	0.585 (legacy 0.649)	854/1000	2.67

V2 là minh họa tốt cho thất bại của trực giác “chỉ cần fine-tune lời giải là đủ”. Dù mô hình được phép sinh rationale dài, official-valid chỉ đạt 0.585, và khoảng 14.6% output còn không parse được đáp án cuối. Nếu nhìn dưới lăng kính metric, v2 học không hiệu quả vào nơi metric cần nó mạnh nhất. Điều này dẫn đến insight về nhánh compact reasoning có khả năng cải thiện một phần bức tranh.

Bảng VII

CÁC PHIÊN BẢN THỬ NGHIỆM VỚI MỤC TIÊU SUY LUẬN NGẮN. SO VỚI v9, v10 RÚT NGẮN OUTPUT GẦN MỘT NỬA, TĂNG EXTRACTABILITY RÕ RỆT VÀ TĂNG OFFICIAL-VALID, NHƯNG SOURCE-DISJOINT GẦN ĐỨNG YÊN.

Ver	Target	Selection split	Valid score	Source-disjoint score	Avg output length	Reasoning consistency
v3	answer → compact NL	valid	—	—	—	—
v9	compact equations	source-disjoint	1.842	1.392	83.6	extractable 959/1000
v10	curriculum compact	source-disjoint	2.131	1.396	37.5	extractable 990/1000

So sánh v9 với v10 là một trong những bằng chứng quan trọng nhất của toàn báo cáo. Official-valid tăng từ 1.842

lên 2.131 — tức tăng khoảng 15.7% — và extractability từ 959/1000 lên 990/1000. Nhưng source-disjoint score chỉ nhích từ 1.392 lên 1.396, tức gần như không thay đổi có ý nghĩa. Đây chính là mẫu hình cải thiện tín hiệu phản hồi mà không cải thiện khả năng suy luận. Cách diễn giải hợp lý nhất là v10 học tốt hơn việc đưa final answer ra đúng neo/parser, không phải học thêm nhiều về transfer reasoning sang source mới.

Nhánh answer-only LoRA mới là nơi metric alignment thật sự phát huy tác dụng. Ở đây có hai nhận xét rất mạnh. Thứ nhất, v6_fast (hay v6*) với $r = 16$ gần như ngang v6 với $r = 32$, xác nhận rằng rank LoRA không phải nút thắt chính ở pha đầu. Thứ hai, v8 tăng lên 5.265, tức cao hơn v6 khoảng 190.9%, dù family phương pháp cơ bản vẫn là answer-only LoRA. Điều thay đổi chủ yếu là checkpoint selection và quá trình train dài hơn. Nói cách khác, thứ đem lại phần lớn credit ở đây là alignment với metric và model selection đúng split, chứ không phải reasoning text dài hơn.

Bảng VIII

CÁC PHIÊN BẢN ANSWER-ONLY LORA. ĐIỂM VALID TĂNG LỚN NHẤT ĐẾN TỪ TARGET ALIGNMENT VÀ CHECKPOINT SELECTION, KHÔNG PHẢI TỪ VIỆC TĂNG RANK LORA ĐƠN THUẦN.

Ver	Prompt	LoRA config	Epochs	Selection	Valid score	Overlap-valid score
v6	no type	$r = 32$	3	final epoch	1.810	—
v6*	no type	$r = 16$	2.25	final epoch	1.789	—
v8	no type	$r = 32$	8	valid checkpoint	5.265	—
v11	type-aware	$r = 32$	8	overlap-valid checkpoint	4.329	4.696


Reward tuning quy mô nhỏ theo kiểu GRPO-lite không giúp được nhiều, được thể hiện qua 2 phiên bản thử nghiệm GRPO-Lite v5 và v7. Kết quả này khá nhất quán với trực giác về small LM: nếu reward gần metric nhưng rollout budget và verifier yếu, RL khó tạo ra reasoning transfer thật; còn nếu reward ép rationale, mô hình nhỏ lại dễ hy sinh final-answer reliability.

Bảng IX

KẾT QUẢ TÍNH CHÍNH GRPO-LITE. VỚI BUDGET RL NHỎ, REWARD TUNING KHÔNG THẮNG ĐƯỢC SFT/LoRA ANSWER-CENTRIC VÀ THẬM CHỈ CÒN KÉO GIẢM EXTRACTABILITY KHI ÉP MÔ HÌNH REASONING QUÁ SỚM.

Ver	Reward components	PenalizeScore answer-only?		Runtime	Failure mode
v5	numeric + anchor	no	0.955	8.0 min RL	score did not improve beyond SFT baseline
v7	numeric + anchor + reasoning	yes	0.639	20.9 min RL	lower extractability and low answer reward

Retrieval mới là bước nhảy cuối cùng. So sánh v11 với v12 cho thấy chỉ cần thêm retrieval “broad” là official-valid tăng +1.865. Nhưng v12 cũng dùng retrieval tới 90.9% mẫu, và vẫn bị v13 vượt. v13 chỉ retrieval 62.5% mẫu mà official-valid lên 6.896, tức cao hơn v12 khoảng 11.3% tương đối. Đây là dấu hiệu rất rõ rằng precision của gate quan trọng hơn coverage thô. Broad retrieval tạo quá nhiều can thiệp; selective type-gated retrieval mới thật sự tối ưu.



Hình 6. Type-wise official-valid score comparison. v13 là cấu hình cân bằng nhất; v14 FOBAR/SV chỉ nhỉnh hơn ở vài type dễ hơn nhưng đánh đổi bằng sự sụt giảm rất mạnh ở các type khó.

Figure 7 và Figure 6 làm rõ retrieval đã giúp chính xác ở đâu và không giúp ở đâu. Từ Figure 7, v14 sweep có gain dương mạnh ở GSM_Rephrased (+1.051), GSM_AnsAug (+2.962), MATH_AnsAug (+2.913) và MATH_Rephrased (+2.422), trong khi bằng 0 ở cả FOBAR và SV vì gate bị tắt. Khi chuyển sang v14 FOBAR/SV, retrieval usage trên GSM_FOBAR, GSM_SV, MATH_FOBAR, MATH_SV tăng lần lượt tới khoảng 67.2%, 70.1%, 48.9%, 53.7%, nhưng gain trở

thành -0.934 ở GSM_FOBAR, +0.536 ở GSM_SV, -1.267 ở MATH_FOBAR, và -0.073 ở MATH_SV. Đây là bằng chứng gần như trực tiếp rằng retrieval ở đây không phải “solver”: nó chỉ hữu ích khi source/type đủ ổn định. Với perturbation khó hơn, memory heuristic còn có thể hại kết quả.

Figure 6 củng cố cùng kết luận bằng heatmap type-wise. v13 giữ mức rất cao ở các type dễ: GSM_Rephrased 9.51, MATH_Rephrased 8.51, MATH_AnsAug 7.50, đồng thời vẫn hơn v14 sweep ở các type khó như GSM_FOBAR (3.20 vs 2.99), GSM_SV (4.92 vs 4.36), MATH_FOBAR (4.56 vs 4.42). v14 FOBAR/SV chỉ nhỉnh hơn v13 ở MATH_AnsAug và MATH_Rephrased, nhưng suy sụp mạnh ở GSM_FOBAR xuống 1.34 và MATH_FOBAR xuống 2.69. Một retrieval policy tốt cho overlap-friendly types không thể mặc định mở rộng sang perturbation types.

B. Bảng phụ cho các phiên bản retrieval

V. MATH REASONING VỚI CÁC MÔ HÌNH NHỎ


VI. REFERENCES

TÀI LIỆU

Bảng X

CÁC PHIÊN BẢN THỬ NGHIỆM SOURCE-AWARE RETRIEVAL. RETRIEVAL LÀM TĂNG ĐIỂM RẤT MẠNH, NHƯNG CHÍNH MỨC TĂNG ĐÓ PHẢI ĐƯỢC ĐỌC NHƯ BẰNG CHỨNG CỦA EXPLICIT MEMORY, KHÔNG PHẢI BẰNG CHỨNG TRỰC TIẾP CỦA REASONING NỘI TẠI.

Version	Retrieval	Allowed types	Gate	Model fallback	Official-valid score	Overlap-valid score	Source-disjoint score	Retrieval usage
v11	no	none	none	yes	4.329 (4329/10000)	4.696 (4696/10000)	–	0%
v12	yes	broad	majority frac	yes	6.194 (6194/10000)	5.374 (5374/10000)	–	90.9%
v13	yes	Rephrased/AnsAug	type gate	yes	6.896 (6896/10000)	6.337 (6337/10000)	–	62.5%
v14 sweep	yes	selected types	tuned thresholds	yes	6.806 (6806/10000)	6.145 (6145/10000)	–	61.6%
v14 FOBAR/SV	yes	extended	strict nearest	yes	6.379 (6379/10000)	5.846 (5846/10000)	–	82.2%



Hình 7. Hybrid gain versus retrieval usage by type. Gain lớn tập trung ở Rephrased/AnsAug; việc ép retrieval sang FOBAR/SV có thể làm gain âm.

Bảng XI
TỔNG HỢP LỰA CHỌN MÔ HÌNH CUỐI CÙNG.

Candidate	Official-valid score	Source-disjoint score	Overlap-valid score	Runtime	Reasoning quality
Best answer-only	4.329	–	4.696	–	low/medium
Best compact reasoning	2.131	1.396	–	200.4	medium
Best hybrid retrieval (v13)	6.896	–	6.337	177.7	retrieval-dependent
v14 gate sweep	6.806	–	6.145	169.0	retrieval-dependent
v14 FOBAR/SV retrieval	6.379	–	5.846	131.0	retrieval-dependent; weak FOBAR/SV